

M. Soric¹, C. Gracianne², I. Manolescu³, P. Senellart¹

¹DI ENS, ENS, PSL University, CNRS, Paris, France, ²BRGM, Orléans, France, ³Institut Polytechnique de Paris, Palaiseau, France

Le défi GéolAug

Dans le cadre du défi “Géologue Augmenté” entre l’Inria et le BRGM, ma thèse se concentre sur l’exploitation et structuration des données et de connaissances géologiques hétérogènes. Nous nous sommes intéressés à l’extraction d’un type de donnée spécifique (les tableaux). Les tableaux sont “visuellement structurés” mais pas dans les documents PDF.

Définition des tâches

- Détection de Tableaux : trouver les tables dans un document
- Détection de Structure de Tableaux : extraire la structure et le contenu des tableaux
- Extraction de Tableaux : DT + DST




Fig. 2: Extraction bout-en-bout de tableaux (DT + DST)




Fig. 1: Détection de tableau avec VGT [1] et ses scores de confiance sur un document BRGM

Méthodes et jeux de données

Libraires Python :

- Méthodes heuristiques
- Modèles : Camelot, PyMuPDF, PdfPlumber

Autre Types :

- GROBID [2] : PDF parser, utilisé dans HAL
- LVLN : GPT-4o-mini, zero shot learning

Réseaux de neurones, pour détection d’objets :

- Docling [3] : librairie Python utilisant des transformer RL-DETR et TableFormer
- TATR [4] : DETR fine-tune sur DT et RST
- XY+TATR : TATR avec preprocessing
- VGT [1] : détection de mise en page de document avec VGT

End-to-End Model	Input type	Location	Conf. score	HTML	Steps
Camelot	PDF	✓		✓	1
Pymupdf	PDF	✓		✓	1
PdfPlumber	PDF	✓		✓	1
Grobid	PDF	✓		✓	1
LVLN	Image			✓	1
Docling	PDF	✓		✓	2
TATR	Image	✓	✓	✓	2
XY+TATR	Image	✓	✓	✓	2
VGT	Image	✓	✓	✓	2

Fig. 3: Synthèse des méthodes comparées

Métriques et jeux de données

Détection de Tableaux :

- Courbes Précision-Rappel @ IoU 50 %
- Courbes Espérance Précision-Espérance Rappel (variation du seuil IoU)
- Scores de confiance (Detection Expected Calibration Error)

Methodologie

- Dans la littérature les tâches DT et DST sont traités indépendamment.
- Nous voulons aussi évaluer les modèles de bout-en-bout (les systèmes complets).
- D’où l’introduction de nouvelles métriques ET.

Jeux de données (85k images)

- PubTables : jeu de donnée provenant de PubMed [4]
- Table-arXiv : génération d’un jeu de données à partir de code source .tex de papier arXiv
- Table-BRGM : documents de BRGM manuellement annotés

Détection de Structure de Tableaux :

- Tree-Edit-Distance-Based Similarity [5] : tableaux représentés sous forme d’arbre
- GriTS Topology, Content [6] : tableaux représentés sous forme de matrices

Extraction de Tableaux :

- Courbes Précision-Rappel pondérées par les scores DST (GriTS Topology, Content, TEDS)

Résultats




Fig. 4: Courbes Precision—Rappel @ IoU 50 % et avec métriques RST (GriTS Topology, Content, TEDS) sur Table-arXiv

Lire le graphique

- DT : Precision—Rappel @ IoU 50 % (courbes pleine et cercles)
- TE : Precision—Rappel avec métriques RST (courbes pointillées et triangles)

Résultats DT / ET

Les scores DT sont nuancés par les scores ET (qui prennent en compte la RST) ce qui diminue clairement les scores Précision et Rappel.




Fig. 5: Calibration des scores de confiances sur Table-BRGM

Score de confiance

Les scores de confiance de VGT sont calibrés (alignés sur la précision du modèle), ce qui les rend utilisables en pratique contrairement à TATR et XY.

Le problème n’est pas résolu, notamment lorsqu’on prend l’extraction bout-en-bout, même si des . Les résultats obtenus dépendent du jeu de donnée. VGT permet la prise en compte des scores de confiance tandis que Docling obtient les meilleurs les résultats sur les 3 jeux de données.

Références : [1] Da, Cheng, et al. "Vision grid transformer for document layout analysis." Proceedings of the IEEE/CVF international conference on computer vision. 2023. [2] Lopez, Patrice. "Grobid." 2008 [3] Auer, Christoph, et al. "Docling technical report." arXiv preprint arXiv:2408.09869 (2024). [4] Smock, Brandon, et al. "PubTables-1M: Towards comprehensive table extraction from unstructured documents." Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022. [5] Zhong, Xu, et al. "Image-based table recognition: data, model, and evaluation." European conference on computer vision. Cham: Springer International Publishing, 2020. [6] Smock, Brandon, et al. "GriTS: Grid table similarity metric for table structure recognition." International Conference on Document Analysis and Recognition. Cham: Springer Nature Switzerland, 2023.